

## DETEKSI KUALITAS BUAH DENGAN MENGGUNAKAN CNN UNTUK MENAMBAH NILAI JUAL

Zhuliana Melva Rey<sup>\*1)</sup>, Mohammad Fahrul Islami<sup>\*2)</sup>, Najib Rifai Indrayanto<sup>\*3)</sup>

<sup>\*</sup>Jurusan Informatika, Universitas Diponegoro

<sup>1)</sup>zhuliana@students.undip.ac.id, <sup>2)</sup>mohamadfahrulislami@students.undip.ac.id,

<sup>3)</sup>najibrifaiindrayanto@students.undip.ac.id

### Abstrak

*Pada penelitian ini kami mengeksplorasi penerapan Convolutional Neural Networks (CNNs) untuk pendeteksian kualitas buah dengan tujuan untuk meningkatkan nilai jual buah. Penelitian ini menggunakan dataset FruitNet, yang terdiri dari citra buah apel, pisang, jambu biji, lemon, dan delima berkualitas tinggi, yang dikategorikan ke dalam kelas kualitas baik, kualitas buruk, dan kualitas campuran. Dataset dimasukkan melalui pra-pemrosesan gambar, yang meliputi pelabelan, pembuatan kerangka data, dan metode augmentasi sampel untuk memperluas variasi sampel. Model yang mendasarinya, MobileNet, model terlatih dengan reputasi akurasi dan kemanjuran, digunakan, dan dilengkapi dengan lapisan ekstra padat dan penyatuan rata-rata global. Untuk menghindari overfitting, model dioptimalkan menggunakan penghentian awal dan dilatih menggunakan fungsi kerugian lintas-entropi kategorikal. Temuan ini mengungguli penelitian sebelumnya dan menunjukkan akurasi yang sangat baik sebesar 97,95% dalam menentukan kualitas buah. Dengan menawarkan metode deteksi buah yang dapat dipercaya menggunakan CNN, memungkinkan kontrol kualitas yang lebih baik, dan meningkatkan nilai jual buah, penelitian ini menguntungkan sektor buah.*

**Kata kunci :** CNN, kualitas buah, FruitNet, MobileNet

### Abstract

*In this study, we explore the application of Convolutional Neural Networks (CNNs) for fruit quality detection with the aim of enhancing the sales value of fruits. The research utilizes the FruitNet dataset, consisting of high-quality images of apple, banana, guava, lemon, and pomegranate fruits, categorized into good quality, bad quality, and mixed quality classes. The dataset is put through image pre-processing, which includes labeling, dataframe creation, and sample augmentation methods to broaden sample variety. The underlying model, MobileNet, a pre-trained model with a reputation for accuracy and efficacy, is used, and it is supplemented with extra dense layers and global average pooling. In order to avoid overfitting, the model is optimized using early stopping and trained using the categorical cross-entropy loss function. The findings outperform earlier studies and demonstrate an excellent accuracy of 97.95% in determining fruit quality. By offering a trustworthy method for fruit detection using CNNs, enabling better quality control, and increasing the sales value of fruits, this research benefits the fruit sector.*

**Keywords :** CNN, fruit quality, FruitNet, MobileNet

## 1 PENDAHULUAN

Pada kuartal I dan kuartal II tahun 2021 Indonesia mengalami pertumbuhan sebesar 3,01% dan 1,84% pada subsektor pertanian yaitu hortikultura hal ini disebabkan karena pengembangan hortikultura berorientasi ekspor sehingga produktivitas, kualitas, dan kontinuitas dari hortikultura mengalami peningkatan. Dalam hal ini tanaman hortikultura atau buah-buahan tidak hanya mengalami peningkatan ekspor ke luar negeri namun juga mengalami peningkatan pemasaran di dalam negeri. Oleh sebab itu efektivitas dan efisiensi dalam tahap pemilihan buah berkualitas menjadi hal penting mengingatnya pertumbuhan ekspor pada subsektor ini sehingga memungkinkan pemilihan buah berkualitas dengan menggunakan pendekatan berbasis kecerdasan buatan. Namun dalam penerapannya diperlukan serangkaian tahap evaluasi agar mendapatkan hasil yang diinginkan karena tidak terlepas dari faktor dan aspek yang mempengaruhinya.

Beberapa aspek pasti mempengaruhi evaluasi kualitas buah. Termasuk akurasi, sangat penting untuk memastikan bahwa buah diidentifikasi secara akurat berdasarkan beberapa parameter kualitas seperti warna, ukuran, bentuk dan tekstur. Untuk meminimalkan bias manusia dan ketidaksesuaian dalam penilaian, evaluasi objektif diperlukan. Efisiensi sangat penting untuk menyederhanakan proses evaluasi dan meningkatkan produksi. Pada dunia nyata memungkinkan pengambilan keputusan yang cepat, mendukung penyortiran dan penilaian buah yang cepat. Sehingga, teknik evaluasi secara otomatis lebih disukai untuk menjaga integritas buah selama penilaian kualitas buah.

Dalam penelitian Nasiri, dkk. [1], algoritma CNN untuk mengklasifikasi buah kurma dengan akurasi 96.98%. Serta pada penelitian Pariselvam, dkk. [2] mengatakan bahwa Convolution Neural Networks telah digunakan untuk beberapa tantangan pengenalan objek dan segmentasi citra biologis. Sehingga sangat tepat pada penelitian ini menggunakan CNN sebagai deteksi kualitas buah

Kualitas buah bisa dilihat melalui kondisi kulit yang mana kulit buah dapat memberikan petunjuk tentang kualitas buah. Buah dengan kulit yang rusak atau cacat seperti memar atau goresan mungkin memiliki kualitas yang buruk. Hal ini dapat mengindikasikan bahwa buah telah rusak atau terkena serangan hama, sedangkan buah dengan kulit yang sehat dan segar mungkin lebih berkualitas. Selain itu juga ukuran buah juga dapat mempengaruhi kualitas buah. Buah yang terlalu kecil mungkin tidak memiliki rasa atau tekstur yang diinginkan, sedangkan buah yang terlalu besar mungkin kehilangan rasa dan nutrisi yang diinginkan.

Klasifikasi kualitas buah memiliki pentingnya untuk meningkatkan pasar dan membangun standar kualitas yang lebih baik. Namun, jika dilakukan secara manual, prosesnya akan lambat dan dapat mengalami kesalahan, apabila kualitas buah dipetakan ke dalam sistem otomatis menggunakan bahasa pemrograman yang tepat, maka pekerjaan pemilihan buah akan lebih cepat dan akurat. Dengan demikian, proses pemilihan buah akan menjadi lebih efisien dan mengurangi biaya. Saat ini, teknik pembelajaran mesin (machine learning) semakin banyak dimanfaatkan di industri buah, khususnya dalam aplikasi deteksi kesegaran buah. Convolutional Neural Network (CNN) digunakan untuk mengenali ukuran, bentuk dan warna buah yang berbeda sampel [3].

Produksi buah skala besar menjadi layak ketika teknologi yang disarankan mudah digabungkan ke dalam operasi pemilihan dan penilaian kualitas. Skalabilitas ini sangat penting untuk memenuhi permintaan pasar yang meningkat akan buah yang berkualitas tinggi. Menurut Naranjo-torres dkk [4] bahwa deteksi dan klasifikasi kualitas buah yang akurat adalah salah satu tugas penting untuk menghindari kehilangan nilai tambah di pasar. Untuk itu, upaya terus menerus dilakukan untuk memperbaiki metode pendeteksian kerusakan, penyakit, dan tingkat kematangan buah.

Saat ini, deep learning (DL) adalah salah satu metode berbasis ML yang paling banyak digunakan. Karakteristik penting dari DL adalah memiliki tingkat abstraksi yang tinggi dan kemampuan untuk secara otomatis mempelajari pola yang ada dalam gambar [4]. Dengan menerapkan algoritma CNN, meningkatkan akurasi evaluasi kualitas buah. CNN memberikan pendekatan yang lebih objektif dan dapat dipercaya daripada pendekatan manual, yang rentan terhadap subjektivitas dan ketidakkonsistenan. Dengan menjamin bahwa hanya buah berkualitas tinggi yang mencapai pasar, akurasi yang lebih tinggi dapat meningkatkan nilai jual produk.

Dengan menggunakan model CNN yang dapat mengklasifikasikan buah secara akurat berdasarkan berbagai atribut kualitas seperti mengenali ukuran, bentuk dan warna sampel buah yang berbeda [3]. Sistem ini akan memungkinkan petani dan distributor buah untuk menilai kualitas buah dengan cepat dan andal, yang mengarah pada pengambilan keputusan yang lebih baik dalam hal proses penyortiran, penilaian, dan distribusi. Otomasi proses identifikasi kualitas diharapkan mengurangi biaya tenaga kerja, meningkatkan efisiensi dan akurasi proses penyortiran [2]. Serta peningkatan nilai jual juga menjadi tujuan dibuatnya model CNN untuk deteksi kualitas buah.

## **2 TINJAUAN PUSTAKA**

Deteksi kualitas buah merupakan salah satu aspek penting dalam industri pertanian dan pemasaran produk buah. Kualitas buah yang baik tidak hanya mempengaruhi citra merek dan kepuasan pelanggan, tetapi juga berdampak langsung pada nilai jual dan daya tahan produk. Oleh karena itu, pengembangan metode yang efektif dan efisien untuk mendeteksi kualitas buah menjadi sangat penting dalam upaya meningkatkan mutu dan efisiensi dalam industri tersebut.

Masalah utama dalam deteksi kualitas buah adalah perlunya melakukan penilaian yang akurat dan konsisten terhadap buah yang beragam dalam kondisi dan tingkat kematangan. Metode tradisional yang melibatkan penilaian manusia cenderung memakan waktu, mahal, dan rentan terhadap kesalahan subjektivitas. Selain itu, dengan volume produksi yang tinggi, memerlukan pengujian manual yang intensif menjadi tidak efisien. Selain itu, variasi pencahayaan, warna, tekstur, dan bentuk buah dapat mempengaruhi kesulitan dalam pengenalan dan klasifikasi kualitas buah. Pola-pola visual yang kompleks dan tidak linear yang mewakili perbedaan antara buah segar, matang, dan busuk sulit diidentifikasi secara manual.

Dalam hal ini, penggunaan Convolutional Neural Network (CNN) sebagai metode deteksi kualitas buah menjanjikan solusi yang lebih akurat, efisien, dan konsisten. CNN mampu mengekstraksi fitur-fitur penting dari gambar buah dan mempelajari pola-pola

kompleks yang berkaitan dengan kualitas buah secara otomatis. Dengan melatih model CNN menggunakan dataset yang mencakup berbagai variasi kualitas buah, dapat dikembangkan model yang mampu mengklasifikasikan buah dengan tingkat akurasi yang tinggi.

Penerapan CNN dalam deteksi kualitas buah dapat membantu meningkatkan efisiensi dan keandalan dalam industri pertanian dan pemasaran buah. Dengan memiliki sistem deteksi kualitas buah yang otomatis, dapat mengurangi biaya dan waktu yang dibutuhkan dalam penilaian manual, serta meningkatkan kepuasan pelanggan dan citra merek melalui produk buah yang berkualitas tinggi.

Dalam beberapa tahun terakhir, penelitian terkait penggunaan CNN untuk mendeteksi tingkat kematangan suatu buah pernah dilakukan. Hal ini dilakukan seperti pada pengklasifikasian butiran halus dari tahapan pematangan pisang berdasarkan gambar melalui arsitektur CNN yang dirancang khusus untuk karakteristik unik dari penampilan pisang [5]. Arsitektur CNN yang telah dirancang juga menghasilkan akurasi klasifikasi yang tinggi. Dalam penelitian tersebut menggunakan dataset sejumlah 17.312 citra pisang dimana pisang tersebut terbagi menjadi dua puluh kelompok dengan sampel sejumlah 197 pisang dengan ukuran, warna serta berat yang sama [5]. Berdasarkan percobaan tersebut diperoleh hasil akurasi sebesar 94,4% pada tingkat laboratorium.

Selain digunakan dalam pengklasifikasian tingkat kematangan pisang, CNN juga diterapkan dalam pendeteksian bentuk normal dari suatu buah. Pada penelitian yang telah dilakukan Momeny dkk [6] dalam pendeteksian kecacatan dari buah ceri berdasarkan bentuk buah ditujukan untuk meningkatkan daya jual dan mencegah pengeluaran biaya yang lebih pada tahap pengemasan. Pada pengklasifikasian tersebut, model CNN diimplementasikan menggunakan pooling berdasarkan metode hybrid pooling dengan menggunakan 719 sampel buah ceri dari dua varietas dan dilakukan augmentasi sehingga mendapat 14.380 citra. Setelah dilakukan pengujian dan dipetakan ke dalam confusion matrix diperoleh akurasi sebesar 99,4% dan berhasil mendeteksi dengan benar 1095 buah ceri pada 1428 citra ceri selama pengujian [6].

Penelitian langsung terkait deteksi kesegaran buah menggunakan pendekatan CNN pernah dilakukan Harsh dkk [3] dimana arsitektur dari model CNN menggunakan dua jalur dengan lapisan terdiri atas CNN dengan pooling maksimum dan lapisan kedua terdiri dari lapisan fully connected. Buah sebagai kumpulan data dari model ini terdiri atas 12 kategori berbeda dengan empat buah berbeda dimana masing-masing buah dibagi lagi kedalam kategori mentah, robek, dan sangat robek [3]. Pada klasifikasi yang dilakukan menggunakan model yang telah dibangun, berhasil mendapat hasil akurasi yang tinggi dimana 96,85% apel berhasil terdeteksi sebagai apel matang.

Dalam penelitian Zhang dkk [7], berfokus pada tingkat kematangan buah pisang dengan ukuran, warna dan berat yang sama menggunakan algoritma CNN yang memperoleh akurasi 94,4% dan pada penelitian Momeny dkk [6], digunakan algoritma CNN dalam mendeteksi kecacatan pada ceri untuk meningkatkan nilai jual dan mengurangi biaya pengemasan yang mendapatkan hasil akurasi tinggi yaitu 99,4%, sedangkan pada penelitian Harsh dkk [3] yang mendeteksi kesegaran buah apel dengan pendekatan CNN diperoleh hasil akurasi 96,85%.

Namun, dengan hasil akurasi yang tinggi pada algoritma CNN, penelitian-penelitian tersebut berfokus pada satu buah saja dalam mendeteksi kualitas buah seperti pisang, ceri dan apel. Pada penelitian ini, digunakan sebuah dataset FruitNet yang berisi 19.526 citra dari 6 kelas buah yang berbeda yakni apel, pisang, jambu biji, lemon, jeruk, dan delima yang dibagi lagi menjadi 3 kelas kualitas buah yaitu buah yang buruk, buah yang baik, dan buah campuran. Dengan algoritma CNN yang memiliki akurasi tinggi dalam mendeteksi kualitas buah, diharapkan hal yang sama dalam mendeteksi kualitas dari 6 kelas buah dari dataset FruitNet.

### 3 METODE PENELITIAN

Penelitian ini berisi beberapa aktivitas yaitu pengumpulan data, *image pre-processing*, *pre-trained model*, *training model*, dan *testing model*.

#### 3.1 Pengumpulan Data

Dalam penelitian ini, kami menggunakan dataset FruitNet yang berisi 19.526 citra yang berkualitas tinggi dari 6 kelas buah yang berbeda yakni apel, pisang, jambu biji, lemon, dan delima yang mana buah-buah tersebut dibagi menjadi 3 kelas yaitu good quality, bad quality, dan mixed quality. Ponsel dengan kamera beresolusi tinggi digunakan untuk mengambil gambar. Gambar diambil pada latar belakang yang berbeda dan dalam kondisi pencahayaan yang berbeda. Contoh gambar dapat dilihat pada Gambar 1.



**Gambar 1. Contoh gambar buah apel untuk (a) good quality, (b) bad quality, dan (c) mixed quality**

#### 3.2 Image Pre-processing

Setelah seluruh citra yang diperlukan telah didapatkan pada proses *Data Collection* maka langkah berikutnya yaitu mempersiapkan data agar dapat dilakukan pelatihan menggunakan CNN. Dalam tahap *preprocessing* ini dilakukan pembuatan filepath dan label agar mempermudah model mengenali gambar, kemudian label diubah tipenya menjadi kategori. Data tersebut diubah menjadi dataframe dan dapat dilihat hasilnya pada Gambar 2.

Setelah itu dilakukan pemisahan dataframe menjadi 3 bagian yaitu, training, validation, dan testing dengan data validation diambil 20% dari data training. Total data training adalah 12496 gambar, data validation 3124 gambar, dan 3906 gambar untuk data testing. Di dalam data pre-processing dilakukan juga beberapa perubahan pada data citra

seperti melakukan augmentasi berupa rotasi dan *flipping* citra, *rescale* citra menjadi 256x256 pixels.



**Gambar 2. Contoh sample dataset yang sudah diberi label**

### 3.3 Pre-Trained Model

Dalam melakukan pelatihan CNN, penelitian ini menggunakan MobileNet sebagai model pre-trained untuk membantu dalam proses pelatihan dikarenakan MobileNet ini merupakan salah satu model *pre-trained* yang memiliki akurasi tinggi namun tetap ringan untuk diimplementasikan ke dalam pelatihan model secara general. Saat MobileNet



pertama kali dibuat, opsi *include top* diset ke False, dan *input shape* untuk model. Dengan konfigurasi ini, kami dapat menyesuaikan bentuk masukan untuk memenuhi persyaratan khusus kami sambil mengecualikan lapisan MobileNet yang terhubung sepenuhnya. Tensor input MobileNet yang telah dilatih sebelumnya dapat diambil menggunakan properti input model. Model kustom akan dimulai dengan tensor input ini sebagai titik awalnya.

Selanjutnya dilakukan data augmentation menerapkan augmentasi data ke tensor input. Keragaman sampel pelatihan dapat ditingkatkan dengan menggunakan teknik augmentasi data seperti rotasi acak, membalik, atau memperbesar, yang akan meningkatkan generalisasi model. Untuk memastikan bahwa model MobileNet terlatih berfungsi dalam mode inferensi dan menerapkan transformasi yang dipelajarinya tanpa pelatihan lebih lanjut, tensor input yang diperbesar dimasukkan melalui model dengan training diset False. Proses ini mengurangi dimensi spasial dari data yang disediakan dengan mengekstraksi fitur tingkat tinggi darinya.

Setelah MobileNet terlatih, *global average pooling layer* diimplementasikan untuk memadatkan data spasial di seluruh *output map* fitur. Nilai rata-rata untuk setiap *map channel* fitur dihitung selama operasi *pooling*, menghasilkan vektor fitur dengan panjang tetap yang mempertahankan fitur penting sambil menurunkan jumlah parameter secara drastis.

Arsitektur model memiliki dua level tambahan (*dense*) yang terhubung sepenuhnya. Fungsi aktivasi ReLU digunakan dalam 256 unit *dense layer* pertama untuk menambahkan nonlinier. Setelah *dense layer* awal diterapkan, lapisan dropout ditambahkan untuk menonaktifkan 20% neuron secara acak selama pelatihan yang membantu menghindari overfitting. Untuk lebih mengubah fitur yang telah dikumpulkan model, *dense layer* kedua dengan 128 unit dan aktivasi ReLU ditambahkan. Untuk memperoleh probabilitas kelas untuk klasifikasi multi-kelas, output layer dengan 18 unit (menunjukkan jumlah kelas) dan fungsi aktivasi softmax digabungkan.

Kelas Model, yang menerima tensor input dan output sebagai input, digunakan untuk membuat arsitektur model umum. Hasilnya, dapat membuat model kustom yang menggabungkan basis MobileNet yang telah dilatih dengan lapisan tambahan yang disesuaikan untuk tugas klasifikasi tertentu. Menggunakan kelas Model, yang menerima tensor input dan output sebagai input, arsitektur model keseluruhan ditentukan. Ini memungkinkan kami membangun model unik yang menggabungkan basis MobileNet yang telah dilatih dengan lapisan ekstra yang dirancang khusus untuk tugas klasifikasi yang ada.

Kategori *cross-entropy loss function* dipilih untuk konstruksi model karena cocok untuk masalah klasifikasi multi-kelas. Selama pelatihan, bobot model diperbarui menggunakan pengoptimal Adam dengan *base learning rate* 0,0001. Statistik akurasi, yang mengukur persentase sampel yang teridentifikasi dengan benar, digunakan untuk menilai performa model.

### 3.4 Training Model

Model ini melatih convolutional neural network menggunakan data pelatihan yang disediakan dan jumlah epoch yang ditentukan (iterasi di seluruh dataset pelatihan). Jika validasi loss tidak berkurang setelah satu epoch, proses pelatihan dihentikan lebih awal menggunakan callback EarlyStopping. Dengan menghentikan proses pelatihan ketika tidak ada kemajuan yang terlihat, merupakan salah satu cara untuk mencegah overfitting dan menghemat sumber daya komputasi.

### 3.5 Testing Model

Setelah melakukan serangkaian tahapan dari mulai *data collection* hingga *training model*, maka model yang diharapkan sudah berhasil dibuat dan dapat dijalankan. Data testing diambil dari pemisahan data saat data *pre-processing*. Data yang sudah dilabeli sebelumnya dicek apakah data testing memprediksi benar yang sebenarnya benar atau memprediksi salah yang sebenarnya benar.


## 4 HASIL DAN PEMBAHASAN

Setelah data menjalani *pre-processing* gambar, yang mencakup pembuatan jalur file dan label untuk memudahkan pengenalan oleh model, konversi label menjadi kategori, dan transformasi menjadi dataframe. Setelah itu, dataframe dibagi menjadi tiga set: training, validation, dan testing, dengan teknik augmentasi data digunakan untuk menambah variasi sampel. Karena akurasi yang tinggi dan desain yang ringan dari MobileNet, MobileNet digunakan sebagai pre-trained model. *Dense layer* tambahan yang diikuti dengan *global average pooling*. EarlyStopping digunakan untuk mencegah overfitting sementara kategori cross-entropy loss function digunakan untuk membangun model dan melatihnya menggunakan data pelatihan. Terakhir data memiliki kemampuan prediksi model divalidasi menggunakan data pengujian.

### Penentuan Learning Rate

Pada tahap eksperimen untuk menentukan learning rate yang ideal dari model yang dibangun maka dilakukan ujicoba langsung menggunakan lapisan konvolusi dari pre-trained model yaitu MobileNet, jumlah neuron yang digunakan yaitu sebanyak 256 neuron pada lapisan awal dan 128 neuron pada lapisan setelah dilakukan fungsi drop pada model yang dibangun,. Dari penentuan learning rate model dioptimalisasi menggunakan fungsi optimisasi “Adam” dengan learning rate 0,0001. Model mendapatkan hasil yang cukup konvergen pada epoch ke-4 dengan learning rate 0,0001. Hasil eksperimen penentuan ini dapat dilihat pada Gambar 3.





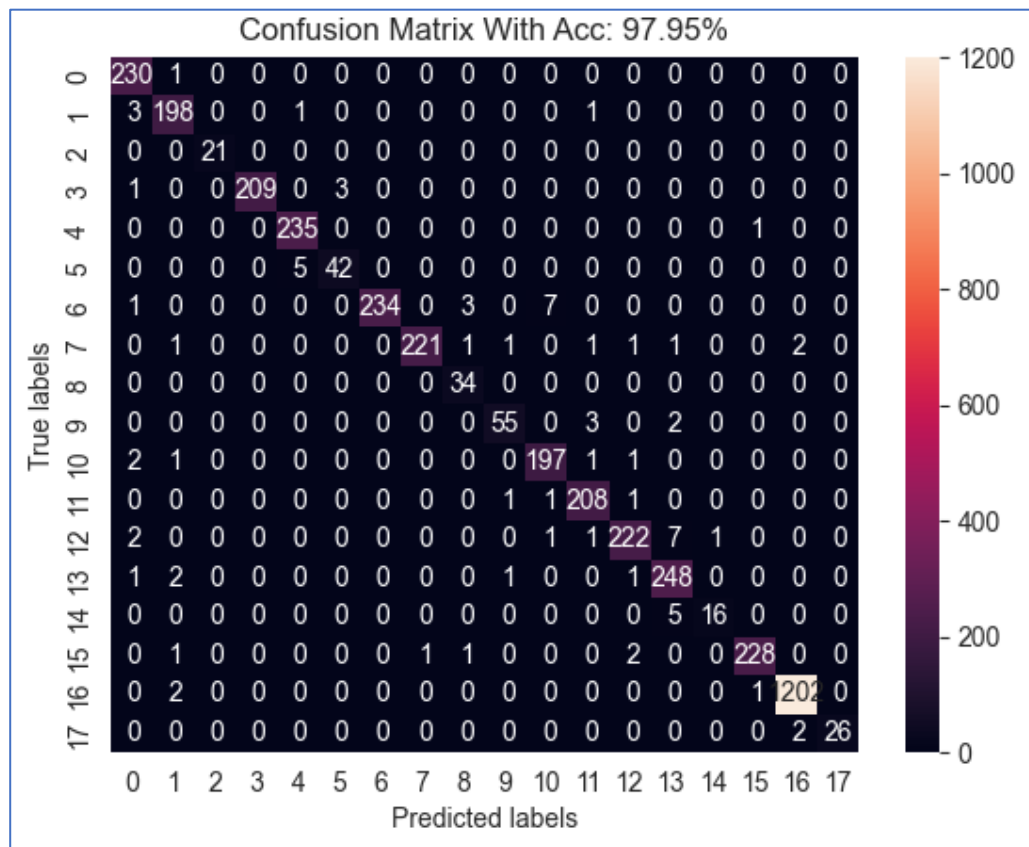
**Gambar 3. Grafik Validation Loss dan Training Loss**

### **Penentuan *Pre-trained* Model**

Dalam penentuan pre-trained model yang digunakan. dilakukan perbandingan ukuran, *Top-1 Accuracy*, *Top-2 Accuracy*, serta waktu komputasi yang diperlukan GPU pada proses pelatihan model. Berdasarkan perbandingan pre-trained model di dalam *library* keras, MobileNet terpilih sebagai model yang memenuhi empat kriteria tersebut. dengan ukuran hanya 16 MB, *Top-1* dan *Top-5 Accuracy* yang tergolong tinggi yaitu masing-masing 70,4% dan 89,5% serta waktu komputasi GPU pada setiap langkah 3.4ms.

### **Hasil Pengujian Pada Dataset Uji**

Pada tahapan pengujian model klasifikasi, dataset uji sebanyak 3.096 citra pada seluruh kelas. Kelas yang diujikan yaitu sebanyak 3 kelas utama berupa kualitas buah “good”, “bad”, dan “mixed” yang masing-masing kelas memiliki sub-kelas buah apel, pisang, jambu, jeruk nipis, jeruk, dan delima sehingga total kelas yang diujikan sebanyak 18 kelas buah dengan masing-masing kualitasnya. Confusion Matrix hasil pengujian dapat dilihat pada gambar 5. Pada hasil tersebut didapatkan akurasi keseluruhan dari pengujian sebesar 97.95% pada dataset FruitNet yang telah dilakukan *splitting* pada tahap data *preprocessing*.



**Gambar 4. Confusion Matrix**

## 5 KESIMPULAN

Berdasarkan hasil dari percobaan dari penelitian ini, dapat disimpulkan bahwa *Convolutional Neural Network* bekerja dengan sangat baik untuk kasus pengklasifikasian kualitas buah, didapatkan hasil akurasi 97,95% untuk mendeteksi kualitas buah dari dataset FruitNet. Sehingga dapat dikatakan bahwa penelitian ini masih unggul dari 2 penelitian sebelumnya. Grafik Train Loss dan Validation Loss mengalami penurunan yang signifikan mendekati 0 sehingga menunjukkan bahwa model belajar dan meningkatkan kinerjanya. Pada confusion matrix juga terlihat bahwa banyak sekali gambar yang terprediksi benar dan benar sehingga model yang dibangun pada penelitian ini sudah cukup bagus untuk diimplementasikan.

## DAFTAR PUSTAKA

- [1] A. Nasiri, A. Taheri-garavand, dan Y. Zhang, "Postharvest Biology and Technology Image-based deep learning automated sorting of date fruit," *Postharvest Biol. Technol.*, vol. 153, no. January, hal. 133–141, 2019, doi: 10.1016/j.postharvbio.2019.04.003.
- [2] S. Pariselvam, P. Anandajayam, dan S. Kalaivani, "Detection of Fruit Quality by CNN Algorithm," vol. 20, no. 6, hal. 80–85, 2018, doi: 10.9790/0661-2006018085.
- [3] A. Harsh, K. K. Jha, S. Srivastava, A. Raj, dan S. Raghav, "FRUIT FRESHNESS DETECTION USING CNN APPROACH," no. 06, hal. 456–463, 2020.

- [4] J. Naranjo-torres, M. Mora, dan R. Hernández-garcía, “A Review of Convolutional Neural Network Applied to Fruit Image Processing,” no. May, 2020, doi: 10.3390/app10103443.
- [5] Y. Zhang, J. Lian, M. Fan, dan Y. Zheng, “Deep indicator for fine-grained classification of banana ’ s ripening stages,” 2018.
- [6] M. Momeny, A. Jahanbakhshi, K. Jafarnejhad, dan Y. Zhang, “Postharvest Biology and Technology Accurate classification of cherry fruit using deep CNN based on hybrid pooling approach,” *Postharvest Biol. Technol.*, vol. 166, no. December 2019, hal. 111204, 2020, doi: 10.1016/j.postharvbio.2020.111204.
- [7] B. Du dkk., “Stacked Convolutional Denoising Auto-Encoders for Feature Representation,” *IEEE Trans. Cybern.*, vol. 47, no. 4, hal. 1017–1027, 2017.